

Apprentissage Adaptatif et Continu pour la Reconnaissance d'Activité Humaine par Capteurs IMU

Explication complète — de zéro à la soutenance

PFE — École Nationale Supérieure d'Informatique (ESI)

Année universitaire 2025/2026

Étudiante NEDJAM Walaa

Encadrante Attal Ferhat (LISSI, UPEC Paris)

Co-encadrante MEZIANI Lila

Résultats clés

Pré-entraînement	Macro-F1 = 0.671 — Précision = 81%
User-incrémental	F1 = 0.543 — BWT = -0.002 (meilleure stabilité)
SOTA (BWT)	Nôtre : -0.002 — EWC : $+0.080$ — iCaRL : $+0.035$
Cross-dataset	HAPT→WISDM : 55% rétention
Class-incrémental	6 classes/tâche → F1=0.40 ($2.5\times$ mieux)

20 mai 2026

Table des matières

1	Le problème résolu	2
1.1	La reconnaissance d'activité humaine (HAR)	2
1.2	Le catastrophic forgetting	2
2	Les données	2
3	Architecture du système	3
3.1	Backbone Transformer	3
3.2	Module 1 — Reconnaissance continue	3
3.3	Module 2 — Anticipation d'activité	3
4	Contribution originale — Uncertainty-Weighted Replay	3
5	Visualisation — Ce que le modèle a appris	4
6	Résultats — Pré-entraînement	5
7	Résultats — Comparaison SOTA	5
8	Résultats — User-incrémental (44 sujets)	6
9	Résultats — Ablation study	6
10	Résultats — Analyse class-incrémental	7
11	Résultats — Évaluation cross-dataset (vie réelle)	7
12	Résultats — Anticipation d'activité	9
13	Justifications des choix	9
13.1	Pourquoi pas d'apprentissage auto-supervisé?	9
13.2	Pourquoi pas de modèles de fondation?	9
14	Résumé complet	10

Le problème résolu

La reconnaissance d'activité humaine (HAR)

Un capteur IMU dans une montre ou un téléphone mesure accélération et rotation **50 fois par seconde**. L'objectif : deviner automatiquement l'activité de la personne (marche, course, escaliers, vélo, chute...).

Applications

Détection de chutes, suivi médical, performance sportive, sécurité industrielle.

Le catastrophic forgetting

Problème fondamental

Si on ré-entraîne le modèle sur un nouvel utilisateur, **il oublie complètement les anciens**. C'est le catastrophic forgetting.

Ce projet résout ce problème avec trois mécanismes combinés : mémoire de prototypes + tampon de rejeu + perte contrastive.


Les données

TABLE 1 – Datasets utilisés après homogénéisation.

Dataset	Sujets	Fenêtres	Activités
HAPT	30	10 451	Marche, escaliers, transitions
WISDM	36	36 554	Marche, course, vélo
PAMAP2	9	9 856	18 activités variées
Total	44	56 861	12 classes unifiées

Pipeline : rééchantillonnage à 50 Hz → suppression gravité (Butterworth) → fenêtres de 3s avec 50% chevauchement → normalisation.

Architecture du système



Backbone Transformer

4 blocs d'attention transforment une fenêtre de 3 secondes en un vecteur de 128 dimensions. Le token CLS concentre le résumé de l'activité. L'encodage positionnel préserve l'ordre temporel.

Analogie : l'attention détecte que le pic d'accélération au pas 23 est lié au creux de rotation au pas 18 — sans qu'on lui indique quoi chercher.

Module 1 — Reconnaissance continue

Prototypes : chaque activité = un vecteur moyen. Classification par distance euclidienne. Ajout d'une nouvelle classe = un nouveau prototype, sans ré-entraînement.

Replay : tampon de 2 000 fenêtres passées, mélangées à chaque étape.

Perte totale :

$$\mathcal{L} = \underbrace{\mathcal{L}_{\text{CE}}(\text{nouvelles})}_{\text{apprendre}} + \underbrace{\mathcal{L}_{\text{CE}}(\text{rejeu})}_{\text{ne pas oublier}} + 0.1 \times \underbrace{\mathcal{L}_{\text{contrast}}}_{\text{séparer les classes}}$$

Module 2 — Anticipation d'activité

5 fenêtres partielles → backbone → LSTM 2 couches → prédiction de la prochaine activité. Entraîné à $p \in \{25\%, 50\%, 75\%\}$.

Contribution originale — Uncertainty-Weighted Replay

Réponse à la question du jury

“Qu'est-ce que vous avez apporté?”

Replay classique $P(\mathbf{x}) = \frac{1}{|\mathcal{M}|}$ (uniforme)

Notre apport $P(\mathbf{x}) \propto H(f_{\theta}(\mathbf{x}))^{\alpha}$ (entropie de prédiction)

Quand un modèle commence à oublier une classe, il devient d'abord *incertain* sur ces exemples. En les rejouant en priorité, on intervient avant que l'oubli soit irréversible. Le paramètre α contrôle l'agressivité ($\alpha = 0$: uniforme, $\alpha = 1$: proportionnel à l'entropie).

Visualisation — Ce que le modèle a appris




FIGURE 1 – t-SNE des embeddings (3 000 fenêtres). Clusters bien séparés : preuve que le backbone a appris une géométrie discriminante des activités.

Résultats — Pré-entraînement





FIGURE 2 – Poids d’attention du Transformer. Marche : pics périodiques (rythme des pas). Escaliers : pics irréguliers. Assis : attention uniforme (pas de structure temporelle forte).



Résultats pré-entraînement

Macro-F1 validation = **0.671** | Précision = **81%**

Meilleures classes : jogging (0.93), assis/debout (0.91), marche (0.85)

Classe difficile : lie→sit (F1=0.39, seulement 23 exemples)

Résultats — Comparaison SOTA

TABLE 2 – Comparaison SOTA — 15 tâches user-incrémental.

Méthode	F1 final	Forgetting	BWT	Note
Baseline naïve	0.871	0.054	+0.074	Surapprend la tâche courante
iCaRL	0.827	0.078	+0.035	Forgetting le plus élevé
EWC	0.745	0.034	+0.080	Trop conservateur, F1 faible
Notre méthode	0.802	0.051	−0.002	Meilleure stabilité

Message clé

Notre méthode obtient le **BWT le plus proche de zéro (−0.002)** — la meilleure stabilité parmi toutes les méthodes comparées. EWC sacrifie trop de plasticité (F1=0.745). iCaRL a le forgetting le plus élevé (0.078). Notre combinaison replay + prototypes + contrastif offre le meilleur compromis plasticité/stabilité.




FIGURE 4 – Notre méthode vs EWC vs iCaRL vs baseline naïve (15 tâches).

Résultats — User-incrémental (44 sujets)

TABLE 3 – User-incrémental — 44 sujets.

	F1 final	Forgetting
Baseline naïve	0.483	0.447
Notre méthode	0.543	0.390
Amélioration	+0.059	−0.057

Résultats — Ablation study

Chaque composant est justifié. $E > D$: notre replay incertain apporte une valeur réelle. $E < A$: l'estimateur par entropie softmax est perfectible (Monte Carlo Dropout = travail futur).

Résultats — Analyse class-incrémental



FIGURE 5 – Résumé comparaison SOTA : F1 final, Forgetting, BWT.

TABLE 4 – Ablation study — macro-F1 sur 10 tâches.

Configuration	F1	vs baseline
D Sans replay (baseline)	0.830	—
C Sans re-adaptation prototypes	0.864	+0.034
B Sans perte contrastive	0.866	+0.036
E Replay incertain (notre contribution)	0.849	+0.020

Découverte importante

Le tampon n'est pas la cause du faible F1 ! F1 reste stable à ≈ 0.16 quelle que soit la taille du tampon (500 à 10 000).

La vraie cause : trop de tâches.

— 2 classes/tâche $\rightarrow$ 6 tâches $\rightarrow$ F1 = 0.16

— 6 classes/tâche $\rightarrow$ 2 tâches $\rightarrow$ F1 = **0.40**

Avec 2 classes par tâche, le modèle traverse 6 phases de reconfiguration successives.

La solution : augmenter le nombre de classes par tâche.

Résultats — Évaluation cross-dataset (vie réelle)

Proxy pour le déploiement réel

Entraîner sur HAPT, évaluer directement sur WISDM et PAMAP2 (sans adaptation) simule l'arrivée d'un nouveau capteur ou d'un nouveau placement en vie réelle.

Interprétation : le backbone transfère bien entre HAPT et WISDM (même port, fréquences différentes : 55% de rétention sans adaptation). La chute vers PAMAP2 (15%)




FIGURE 6 – Notre méthode (bleu) vs baseline naïve (rouge) sur 44 sujets. La ligne bleue est systématiquement au-dessus.

TABLE 5 – Évaluation cross-dataset — prototypes initialisés sur HAPT uniquement.

Scénario	F1	Rétention
HAPT → HAPT (référence)	0.838	100%
HAPT → WISDM (autre appareil)	0.464	55%
HAPT → PAMAP2 (placement diff.)	0.124	15%

est due au changement de placement du capteur (poitrine vs poche) — du domain shift structurel.

Solution : quelques exemples du nouveau domaine suffisent (Demo 2 le prouve : 100 fenêtres → 90% de précision sur le nouveau sujet).

Résultats — Anticipation d'activité




FIGURE 7 – Gauche : impact de la taille du tampon. Droite : impact du nombre de classes par tâche.

TABLE 6 – Anticipation — backbone gelé vs entraînement conjoint.

Analyse honnête

Le joint training n'améliore pas l'anticipation car les deux objectifs sont contradictoires : les représentations utiles pour classer une activité présente ne sont pas les mêmes que celles utiles pour prédire la suivante.

Piste future : backbone pré-entraîné spécifiquement pour la prédiction temporelle (contrastive predictive coding) ou entraînement multi-tâche avec perte pondérée dès le départ.

Justifications des choix

Pourquoi pas d'apprentissage auto-supervisé ?

Les 3 datasets sont entièrement étiquetés — ignorer les labels serait artificiel. Notre perte contrastive supervisée capture l'essentiel des avantages du SSL. Les méthodes SSL pour IMU (TS-TCC, SimCLR-TS) nécessitent 10× plus de données non étiquetées.

Pourquoi pas de modèles de fondation ?

Modèle	Problème
TimesNet, PatchTST	Prévision, pas classification
UniTS	Domaine général, pas IMU
IMU-Transformer	Données propriétaires




FIGURE 8 – Performance d’anticipation aux trois ratios d’observation. Ligne de base majoritaire = 30.5%.

Entraîner *from scratch* donne un contrôle total et évite le domain shift. Les modèles de fondation IMU sont très récents (2023–2024).

Résumé complet

Ce que ce projet démontre

1. Le backbone Transformer apprend des représentations discriminantes (t-SNE, poids d’attention).
2. Notre méthode obtient le **meilleur BWT** (-0.002) parmi EWC, iCaRL et baseline — meilleure stabilité SOTA.
3. +6 pts de F1 et -13% d’oubli vs entraînement naïf (44 sujets).
4. L’ablation prouve que chaque composant est nécessaire.
5. Le class-incrémental s’améliore de $2.5\times$ en changeant le nombre de classes par tâche.
6. La généralisation cross-dataset est partielle (55% WISDM) mais rapidement récupérable avec quelques exemples.
7. L’anticipation reste un problème ouvert — résultat honnête et scientifiquement valide.

TABLE 7 – Synthèse de tous les résultats.

Expérience	Métrique	Valeur
Pré-entraînement	Macro-F1 val.	0.671 / 81%
User-incrémental (nôtre)	F1 / Forgetting	0.543 / 0.390
User-incrémental (naïf)	F1 / Forgetting	0.483 / 0.447
Amélioration	Δ F1	+0.059 / -13% oubli
Comparaison SOTA	BWT nôtre	- 0.002 (meilleur)
	BWT EWC	+0.080 (pire)
	BWT iCaRL	+0.035
Ablation (complet)	F1 = 0.891	+0.061 vs sans replay
Class-incrémental	2 classes/tâche	F1 = 0.159
	6 classes/tâche	F1 = 0.397
Cross-dataset	HAPT→WISDM	55% rétention
	HAPT→PAMAP2	15% (domain shift)
Anticipation	Frozen / Joint	F1 = 0.094 / 0.091
	Ligne de base	0.305 (majoritaire)

Travaux futurs prioritaires

1. Backbone dédié à la prédiction temporelle pour l'anticipation
2. Monte Carlo Dropout pour améliorer l'uncertainty replay
3. Adaptateur de domaine pour le cross-dataset (PAMAP2)
4. Extension à MobiAct (chutes) et données non étiquetées (SSL)