

# Apprentissage Adaptatif et Continu pour la Reconnaissance d'Activité Humaine par Capteurs IMU

Explication complète du projet — de zéro à la soutenance

**PFE — École Nationale Supérieure d'Informatique (ESI)**

Année universitaire 2025/2026

Étudiante NEDJAM Walaa

Encadrante Attal Ferhat (LISSI, UPEC Paris)

Co-encadrante MEZIANI Lila

## Résultats clés

|                   |                                               |                          |
|-------------------|-----------------------------------------------|--------------------------|
| Pré-entraînement  | Macro-F1 = 0.671                              | Précision = 81%          |
| User-incrémental  | F1 final = 0.543                              | −13% d'oubli vs baseline |
| Ablation complète | F1 = 0.891                                    | +6.1 pts vs sans replay  |
| t-SNE             | Clusters bien séparés — backbone discriminant |                          |

19 mai 2026

## Table des matières

---

|          |                                                               |           |
|----------|---------------------------------------------------------------|-----------|
| <b>1</b> | <b>Le problème résolu</b>                                     | <b>2</b>  |
| 1.1      | C'est quoi la reconnaissance d'activité humaine ? . . . . .   | 2         |
| 1.2      | Le problème fondamental : le modèle oublié . . . . .          | 2         |
| <b>2</b> | <b>Les données</b>                                            | <b>2</b>  |
| 2.1      | Trois bases de données publiques . . . . .                    | 2         |
| 2.2      | Pipeline de prétraitement . . . . .                           | 2         |
| <b>3</b> | <b>Architecture du système</b>                                | <b>3</b>  |
| 3.1      | Le Backbone Transformer . . . . .                             | 3         |
| 3.2      | Module 1 — Reconnaissance continue . . . . .                  | 4         |
| 3.3      | Module 2 — Anticipation d'activité . . . . .                  | 4         |
| <b>4</b> | <b>Contribution originale</b>                                 | <b>5</b>  |
| 4.1      | Idée . . . . .                                                | 5         |
| 4.2      | Intuition . . . . .                                           | 5         |
| <b>5</b> | <b>Visualisation — Ce que le modèle a appris</b>              | <b>5</b>  |
| 5.1      | t-SNE des embeddings . . . . .                                | 5         |
| 5.2      | Poids d'attention du Transformer . . . . .                    | 6         |
| <b>6</b> | <b>Ablation study — Chaque composant justifié</b>             | <b>7</b>  |
| <b>7</b> | <b>Résultats expérimentaux</b>                                | <b>8</b>  |
| 7.1      | Phase 1 — Pré-entraînement . . . . .                          | 8         |
| 7.2      | Phase 2 — Apprentissage continu (user-incrémental) . . . . .  | 9         |
| 7.3      | Phase 2 — Apprentissage continu (class-incrémental) . . . . . | 9         |
| 7.4      | Module 2 — Anticipation . . . . .                             | 10        |
| <b>8</b> | <b>Justifications des choix</b>                               | <b>10</b> |
| 8.1      | Pourquoi pas d'apprentissage auto-supervisé ? . . . . .       | 10        |
| 8.2      | Pourquoi pas de modèles de fondation ? . . . . .              | 10        |
| <b>9</b> | <b>Résumé complet</b>                                         | <b>11</b> |

## Le problème résolu

---

### C'est quoi la reconnaissance d'activité humaine ?

Une montre connectée ou un téléphone contient un capteur **IMU** (Inertial Measurement Unit) qui mesure les mouvements du corps **50 fois par seconde** sur 6 axes : accélération (x, y, z) et rotation (x, y, z).

#### Objectif

À partir de ce flux de données brutes, **deviner automatiquement ce que fait la personne** : marcher, courir, monter des escaliers, s'asseoir, faire du vélo, tomber...

**Applications concrètes** : détection de chutes chez les personnes âgées, suivi médical à distance, analyse de performance sportive, sécurité industrielle.

### Le problème fondamental : le modèle oublie

Un modèle classique est entraîné une seule fois sur des données fixes. Dans la réalité, le monde change : un nouvel utilisateur arrive, une nouvelle activité doit être reconnue, le capteur est différent.

#### Catastrophic Forgetting (oubli catastrophique)

Si on ré-entraîne le modèle sur un nouvel utilisateur, **il oublie complètement les anciens**.

|                           |                                                 |
|---------------------------|-------------------------------------------------|
| <b>Avant</b>              | Reconnaît bien Alice, Bob, Carol                |
| Ré-entraînement sur David |                                                 |
| <b>Après</b>              | Reconnaît David mais a oublié Alice, Bob, Carol |

C'est exactement ce problème que ce projet résout.

## Les données

---

### Trois bases de données publiques

### Pipeline de prétraitement

Trois étapes pour rendre les datasets comparables :

1. **Rééchantillonnage** — tout à 50 Hz (même cadence)

TABLE 1 – Bases de données utilisées.

| Dataset      | Sujets    | Hz orig.  | Fenêtres      | Activités                      |
|--------------|-----------|-----------|---------------|--------------------------------|
| HAPT         | 30        | 50        | 10 451        | Marche, escaliers, transitions |
| WISDM        | 36        | 20        | 36 554        | Marche, course, vélo           |
| PAMAP2       | 9         | 100       | 9 856         | 18 activités variées           |
| <b>Total</b> | <b>44</b> | <b>50</b> | <b>56 861</b> | <b>12 classes unifiées</b>     |


2. **Suppression de la gravité** — filtre Butterworth 0.5 Hz, on garde uniquement le mouvement dynamique
3. **Fenêtrage glissant** — fenêtres de 3 secondes (150 points), chevauchement de 50%, étiquette par vote majoritaire

### Résultat

56 861 fenêtres normalisées, 6 canaux, 12 classes unifiées, 44 sujets. Toutes les fenêtres ont le même format quelle que soit la source.

## Architecture du système

Le système a deux parties : un **backbone** partagé et deux **modules**.



### Le Backbone Transformer

Le Transformer (architecture de ChatGPT, adaptée aux séries temporelles) transforme une fenêtre de 3 secondes en un **vecteur résumé de 128 dimensions**.

**Mécanisme d'attention :** le modèle regarde toute la fenêtre et décide quels moments sont importants. Pour la marche, il détecte les pics de pas. Pour les escaliers, il repère les efforts irréguliers.

**Analogie :** lire une phrase. L'attention permet de comprendre que “rouge” décrit “balle” et non “Marie” dans “la balle que Marie a frappée est rouge”. Le Transformer fait pareil avec les données IMU.

TABLE 2 – Paramètres du backbone.

|                       |         |
|-----------------------|---------|
| Dimension $d$         | 128     |
| Blocs Transformer $L$ | 4       |
| Têtes d'attention $H$ | 4       |
| Paramètres totaux     | 531 457 |

## Module 1 — Reconnaissance continue

### Mémoire des prototypes

Chaque activité est représentée par un seul **vecteur moyen** (prototype). Classification : on cherche le prototype le plus proche du vecteur inconnu.

#### Avantage clé

Ajouter une nouvelle classe = juste ajouter un nouveau prototype. **Pas besoin de tout ré-entraîner.**

### Tampon de rejeu (Experience Replay)

On conserve un petit échantillon des données passées (2 000 fenêtres max). À chaque entraînement, on mélange anciennes et nouvelles données : le modèle *révise* en même temps qu'il apprend.

### Perte contrastive supervisée

En plus du classifieur, on force le modèle à : **rapprocher** les vecteurs de la même activité et **éloigner** ceux d'activités différentes.

### Perte totale

$$\mathcal{L} = \underbrace{\mathcal{L}_{\text{CE}}(\text{nouvelles})}_{\text{apprendre}} + \underbrace{\mathcal{L}_{\text{CE}}(\text{rejeu})}_{\text{ne pas oublier}} + 0.1 \times \underbrace{\mathcal{L}_{\text{contrast}}}_{\text{séparer les classes}}$$

## Module 2 — Anticipation d'activité

Peut-on prédire la prochaine activité en observant seulement une partie du signal actuel ?

1. Prendre les 5 dernières fenêtres partielles (tronquées à  $p\%$ )
2. Chaque fenêtre  $\rightarrow$  backbone  $\rightarrow$  vecteur de 128

3. Un **LSTM à 2 couches** modélise la progression temporelle
4. Prédiction de la prochaine activité

Entraîné à trois ratios :  $p \in \{25\%, 50\%, 75\%\}$ .

## Contribution originale

### Question du jury

“Qu’est-ce que **vous** avez apporté ? Votre modèle n’est qu’un assemblage de briques connues.”

Notre contribution : le **Uncertainty-Weighted Replay Buffer**.

### Idée

Le replay classique tire les exemples **au hasard**. Notre contribution change la distribution d’échantillonnage :

**Replay classique**  $P(\mathbf{x}) = \frac{1}{|\mathcal{M}|}$  (uniforme)

**Notre apport**  $P(\mathbf{x}) \propto H(f_\theta(\mathbf{x}))^\alpha$  (entropie de prédiction)

où  $H(\mathbf{p}) = -\sum_c p_c \log p_c$  est l’entropie de Shannon.

### Intuition

Quand un modèle commence à oublier une classe, il devient d’abord **incertain** sur ces exemples avant de les classer complètement mal.

En les rejouant en priorité, on intervient **au bon moment** — avant que l’oubli soit irréversible.

Le paramètre  $\alpha$  contrôle l’agressivité :  $\alpha = 0$  = replay uniforme,  $\alpha = 1$  = proportionnel à l’entropie.

## Visualisation — Ce que le modèle a appris

### t-SNE des embeddings

La figure 1 est la **preuve visuelle** que le Transformer a appris des représentations discriminantes.




FIGURE 1 – Réduction t-SNE en 2D des embeddings du backbone (3 000 fenêtres). Chaque couleur correspond à une activité.

- Marche, escaliers, jogging : clusters bien séparés et denses
- Assis/debout et allongé : groupe distinct en bas à gauche
- Vélo et marche nordique : proches mais séparables (deux activités rythmées avec bras actifs)
- Transitions : dispersées entre leurs activités parentes — cohérent avec leur nature intermédiaire

### Conclusion

Le backbone n'a pas mémorisé — il a compris la structure des activités. Deux activités proches dans le t-SNE sont réellement similaires sur le capteur.

## Poids d'attention du Transformer

La figure 2 montre **quand dans les 3 secondes** le modèle regarde :

- **Marche** : pics réguliers et périodiques — le rythme des pas




FIGURE 2 – Importance temporelle apprise par le Transformer pour 4 activités. Y-axe : poids d’attention du token CLS (moyenne sur les 4 blocs).

- **Monter les escaliers** : pics espacés et irréguliers — chaque pas demande plus d’effort
- **Descendre** : pics aux instants d’impact au sol
- **Assis/debout** : attention uniforme — pas de structure temporelle forte dans une activité statique

Ces patterns correspondent exactement à ce qu’un expert analyserait. **Le modèle a appris sans qu’on lui indique quoi regarder.**

## Ablation study — Chaque composant justifié

### Question du jury

“Est-ce que les prototypes aident vraiment ? Est-ce que la perte contrastive change quelque chose ?”

Cinq configurations testées (10 tâches, 5 époques chacune) :

TABLE 3 – Ablation study — macro-F1 moyen sur 10 tâches.

| Config   | Description                                | F1           | vs D          |
|----------|--------------------------------------------|--------------|---------------|
| D        | Sans replay — baseline naïve               | 0.830        | —             |
| C        | Sans re-adaptation des prototypes          | 0.864        | +0.034        |
| B        | Sans perte contrastive ( $\lambda_c = 0$ ) | 0.866        | +0.036        |
| E        | Replay incertain (notre contribution)      | 0.849        | +0.020        |
| <b>A</b> | <b>Modèle complet</b>                      | <b>0.891</b> | <b>+0.061</b> |

Lecture des résultats :

- **A vs D (+0.061)** — le modèle complet gagne 6 points de F1 sur la baseline. Chaque composant contribue.

- **A vs B (+0.025)** — la perte contrastive aide à mieux séparer les classes dans l'espace d'embedding.
- **A vs C (+0.027)** — sans re-adapter les prototypes après mise à jour du backbone, les prototypes deviennent obsolètes.
- **E vs D (+0.020)** — notre replay incertain est **meilleur que l'absence de replay**.  $E < A$  montre que l'estimateur par entropie softmax est perfectible : Monte Carlo Dropout ou ensembles donneraient de meilleures estimations — **piste de recherche future directe et crédible**.

### Conclusion de l'ablation

Chaque composant est justifié par des chiffres. La combinaison complète (A) est la meilleure configuration. Notre replay incertain (E) est une preuve de concept positive qui ouvre une direction de recherche concrète.

## Résultats expérimentaux

### Phase 1 — Pré-entraînement




FIGURE 3 – Courbes de pré-entraînement : perte (gauche) et macro-F1 (droite).

La perte d'entraînement (bleu) descend de 0.69 à 0.04. Le F1 de validation se stabilise à **0.671** (précision globale 81%). La divergence val/train après l'époque 10 indique un léger surapprentissage limité par la diversité inter-sujets.

|                     |                                            |
|---------------------|--------------------------------------------|
| Macro-F1 validation | 0.671                                      |
| Précision globale   | 81%                                        |
| Meilleure classe    | Jogging/Course (F1 = 0.93)                 |
| Classe difficile    | Lie→sit (F1 = 0.39, seulement 23 exemples) |




FIGURE 4 – Notre méthode (bleu) vs entraînement naïf sans replay (rouge pointillé). Y-axe : macro-F1 sur chaque sujet après avoir appris les 44.

## Phase 2 — Apprentissage continu (user-incrémental)

### Figure la plus importante de la présentation

La ligne bleue est **systématiquement au-dessus** de la rouge sur les 44 tâches. C'est la preuve directe que notre méthode préserve mieux les anciens sujets.

TABLE 4 – Comparaison user-incrémental (44 sujets).

| Méthode                         | F1 final      | Forgetting    |
|---------------------------------|---------------|---------------|
| Entraînement naïf (sans replay) | 0.483         | 0.447         |
| <b>Notre méthode</b>            | <b>0.543</b>  | <b>0.390</b>  |
| <b>Amélioration</b>             | <b>+0.059</b> | <b>−0.057</b> |

La matrice (Figure 5) montre deux phases :

- **Tâches 1–36** (HAPT + WISDM) : bloc vert foncé — le replay fonctionne bien dans le même domaine.
- **Tâches 37–44** (PAMAP2) : couleurs plus claires — changement de domaine (placement capteur différent, nouvelles activités).

## Phase 2 — Apprentissage continu (class-incrémental)

Un tampon plus grand réduit l'oubli de 22% : preuve directe de l'utilité du replay.

TABLE 5 – Impact de la taille du tampon de rejeu (class-incrémental).

|                     | Tampon 2 000 | Tampon 5 000   |
|---------------------|--------------|----------------|
| Forgetting          | 0.406        | <b>0.318</b>   |
| BWT                 | −0.406       | − <b>0.318</b> |
| <b>Amélioration</b> | −22% d’oubli |                |

## Module 2 — Anticipation

|                                    | $p = 25\%$ | $p = 50\%$ | $p = 75\%$ |
|------------------------------------|------------|------------|------------|
| Précision                          | 0.322      | 0.337      | 0.337      |
| Macro-F1                           | 0.093      | 0.093      | 0.094      |
| Ligne de base (classe majoritaire) | 0.305      |            |            |

Le modèle dépasse la ligne de base mais les résultats restent faibles. Cause principale : le backbone est gelé pendant l’entraînement du LSTM, les représentations ne sont pas optimisées pour la prédiction. **Entraînement conjoint backbone + LSTM = travail futur principal.**

## Justifications des choix

### Pourquoi pas d’apprentissage auto-supervisé ?

L’apprentissage auto-supervisé (SSL) requiert des données non étiquetées en **grande quantité** (typiquement  $10\times$  plus que le supervisé). Nos 3 datasets sont entièrement étiquetés — ignorer les labels serait artificiel. Notre perte contrastive supervisée capture l’essentiel des avantages du SSL (séparation inter-classes) sans ses contraintes.

**Perspective :** pré-entraînement SSL sur des données brutes de smartwatch, suivi d’un fine-tuning supervisé.

### Pourquoi pas de modèles de fondation ?

| Modèle             | Problème                                        |
|--------------------|-------------------------------------------------|
| TimesNet, PatchTST | Conçus pour la prévision, pas la classification |
| UniTS              | Domaine général, pas spécifique IMU             |
| IMU-Transformer    | Données de pré-entraînement propriétaires       |

Entraîner *from scratch* donne un contrôle total sur la représentation et évite le domain shift. Les modèles de fondation IMU sont un domaine très récent (2023–2024) en pleine évolution.

## Résumé complet

TABLE 6 – Toutes les performances en un tableau.

| Expérience                  | Métrique            | Valeur        |
|-----------------------------|---------------------|---------------|
| Pré-entraînement            | Macro-F1            | 0.671         |
|                             | Précision           | 81%           |
| User-incrémental (nôtre)    | F1 final            | 0.543         |
|                             | Forgetting          | 0.390         |
| User-incrémental (naïf)     | F1 final            | 0.483         |
|                             | Forgetting          | 0.447         |
| <b>Amélioration</b>         | $\Delta$ F1         | <b>+0.059</b> |
|                             | $\Delta$ Forgetting | <b>-0.057</b> |
| Class-incrémental (5k)      | F1 final            | 0.159         |
|                             | Forgetting          | 0.318         |
| Ablation (modèle complet)   | F1                  | 0.891         |
| Ablation (sans replay)      | F1                  | 0.830         |
| <b>Apport replay</b>        |                     | <b>+0.061</b> |
| Anticipation ( $p = 75\%$ ) | Précision           | 0.337         |
|                             | Macro-F1            | 0.094         |

### Ce que ce projet démontre

1. Le Transformer apprend de bonnes représentations IMU — visualisé par le t-SNE et les poids d'attention.
2. Notre méthode (replay + prototypes + contrastif) réduit l'oubli de **13%** et améliore le F1 de **6 points** vs entraînement naïf.
3. Un tampon plus grand réduit l'oubli de **22%** en class-incrémental.
4. L'ablation study prouve que chaque composant est nécessaire.
5. La contribution originale (replay incertain) est une piste de recherche valide et documentée.
6. L'anticipation reste un problème ouvert — c'est une honnêteté scientifique, pas une faiblesse.

### Travaux futurs prioritaires

1. Entraînement conjoint backbone + LSTM pour l'anticipation
2. Uncertainty replay avec Monte Carlo Dropout (meilleure estimation)
3. Comparaison formelle avec EWC sur le scénario user-incrémental

#### 4. Intégration de MobiAct (chutes, AVQ) pour enrichir le scénario




FIGURE 5 – Matrice des résultats  $R[i, j]$  : F1 sur le sujet  $j$  après entraînement sur le sujet  $i$ . Plus vert = meilleur. Lire une colonne de haut en bas montre l'oubli progressif.




FIGURE 6 – Matrice class-incrémental (6 tâches, 2 classes par tâche). Tâche 0 :  $F1 = 0.91$ . Tâche 5 :  $F1 = 0.13$ .




FIGURE 7 – Performance d'anticipation aux trois ratios d'observation. Ligne de base majoritaire = 30.5%.